

Grupo B:

Ana Carolina Kubo

Danilo de Souza Silva

Jefferson da Silva Almeida

Willian Camargo Aires Maranhão

Plataforma de BI : Análise de Dados no Setor de Alimentação

.....

Pipeline End-to-End

Yelp Dataset → Databricks → Dashboard



Agenda

Visão geral da apresentação



01

Plataforma Yelp e Dataset

02

Objetivos do Projeto

03

Databricks e Arquitetura Medalhão

04

Dashboard — Visão geral

05

Dashboard — Visitas por Período

06

Dashboard — Usuários da Plataforma

07

Dashboard — Análise de inconsistências

08

Desafios, Lições e Próximos Passos

Plataforma Yelp

O que é e por que usá-la como fonte de dados?



Sobre a Plataforma

Yelp é uma plataforma americana de avaliações de negócios locais fundada em 2004, com foco em restaurantes, serviços e comércio.

Permite que usuários publiquem reviews com notas de 1 a 5 estrelas, fotos e check-ins. Conta com mais de 200 milhões de avaliações acumuladas.

O Yelp Open Dataset é disponibilizado para fins acadêmicos, contendo dados reais anonimizados de múltiplas cidades dos EUA e Canadá.



150K+

Negócios



6M+

Usuários



~7M

Reviews



5

Arquivos JSON

Fonte: Yelp Open Dataset — yelp.com/dataset

Dataset

Estrutura e escopo dos dados utilizados

business.json	Dados dos negócios: nome, endereço, categoria, horários, avaliação média	~9,3GB
review.json	Reviews completas: texto, nota, data, useful / funny / cool votes	
user.json	Perfil de usuários: amigos, contagem de reviews, elite status	
checkin.json	Registros de check-ins por negócio e timestamps de visitas	
tip.json	Dicas curtas de usuários sobre estabelecimentos	

★ Foco do projeto: **business.json**, **review.json**, **user.json** e **checkin.json**

Objetivos do Projeto

Questões de Negócio a serem respondidas

01

Descobrir os melhores restaurantes por categoria e localidade (através do Rating Yelp)

Possível caso de uso: **oportunidades de expansão dos melhores restaurantes**

02

Identificar qual dia da semana ou qual mês tem menos visitas por categoria

Possível caso de uso: **campanhas para impulso de vendas, por exemplo: cupom promocional em dias de menor movimento**

03

Identificar os estabelecimentos com reviews inconsistentes

Possível caso de uso: **auditoria de reviews e diminuição do score do usuário na plataforma Yelp**

04

Identificar os top 10 usuários da plataforma

Possível caso de uso: **contrato de influência para criação de conteúdo**

Objetivos do Projeto

O que nos propusemos a construir



Ingestão Automatizada

Construir um pipeline end-to-end desde o Yelp Open Dataset até a camada de apresentação, de forma automatizada e reproduzível no Databricks



Arquitetura Medalhão

Implementar as camadas Bronze, Silver e Gold garantindo qualidade, rastreabilidade e governança dos dados ao longo de todo o pipeline



Dashboard Analítico

Entregar 4 visões interativas: visão geral de restaurantes, visão de visitas, influência de usuários e detecção de inconsistências em avaliações

Plataforma Databricks no Projeto

Aplicação prática dos recursos para processamento do Yelp Dataset

Arquitetura Lakehouse

Fluxo real construído:


Centralização de todo o fluxo de dados: desde o armazenamento bruto dos arquivos JSON extraídos da API do Kaggle (em Volumes na Landing Zone), até a estruturação de tabelas de alto valor analítico para os Dashboards de negócio.

Processamento Distribuído

Uso de PySpark e SQL:

Processamento do alto volume de reviews e manipulação de JSONs complexos. Tratamento de strings de horários para detecção de fraudes e aplicação de cálculos avançados como o Algoritmo Bayesiano.

* Workspace colaborativo com clusters otimizados para o pipeline do Yelp Dataset.



Arquitetura Medalhão

Bronze → Silver → Gold implementadas no Databricks

BRONZE

Ingestão Raw

- Ingestão direta dos JSONs do Yelp
- Dados brutos sem transformação
- Empilhamento de histórico te tabelas
- Preservação do schema original

SILVER

Limpeza e Qualidade

- Limpeza, qualidade e normalização:
 - Verificação de completude
 - Ajuste de precisão numérica
 - Remoção de duplicados
 - Normalização de nomes (abreviações, pontuação, maiúsculas/minúsculas etc.)
- Filtro de categorias de interesse (Restaurante, Padaria, Bar e Bedida e Café) nas 3 tabelas
- Remoção de estabelecimentos fechados
- Remoção de colunas não utilizadas na Gold

GOLD

Prontidão para time de Negócios

- Agregações analíticas para as 4 partes do Dashboard
- 7 tabelas finais:
 - marketing
 - gold_business_reviews_integrado
 - alerta_inconsistencia_estabelecimentos
 - alerta_inconsistencia consolidado_geral
 - alerta_inconsistencia_distribuiçao_temporal
 - alerta_inconsistencia_usuarios
 - alertas_inconsistencia_base
 - user_behavior_complete

Dashboard · Visão Geral de Estabelecimentos de Alimentação

1/3 Visão geral para insights de marketing


Visão geral de Estabelecimentos de Alimentação						
		Total Estabelecimentos	Rating Médio Ajustado		Total de Reviews	
		42,08 mil	3,75		4,09 mi	
Estado	All	Cidade	All	Categoria	All	
Top Estabelecimentos pelo Rating Yelp						
Nome	Categoria	Rating Yelp	Stars Médio	Reviews	Estado	Cidade
TUMERICO	RESTAURANTE	4,81	4,85	724	AZ	TUCSON
YATS	RESTAURANTE	4,79	4,84	637	TN	FRANKLIN
YOLK WHITE & ASSOCIATES	RESTAURANTE	4,79	4,93	230	FL	TAMPA
ICE DREAMMM SHOP	PADARIA	4,78	4,89	315	FL	LUTZ
SMILING WITH HOPE PIZZA	RESTAURANTE	4,78	4,84	549	NV	RENO
THE MEDITERRANEAN CHICKPEA	RESTAURANTE	4,77	4,94	192	FL	TAMPA

> Seleção dos 6 melhores restaurantes pelo Rating Yelp, podendo ser filtrado por: ESTADO, CIDADE, CATEGORIA

Dashboard · Visão Geral de Estabelecimentos de Alimentação

2/3 Visão geral para insights de marketing


Distribuição por Categoria



Categoria

- RESTAURANTE
- BAR E BEBIDA
- CAFE
- PADARIA

Rating por Categoria




> Market share por categoria

> Rating Yelp por categoria

Dashboard · Visão Geral de Estabelecimentos de Alimentação


3/3 Visão geral para insights de marketing



> Visualização de calor pela quantidade de reviews, locais com usuários mais ativos

Rating Yelp por Estado

Comparação do rating ajustado entre estados



> Visualização em barras separados por estado com maior rating yelp

Dashboard · Visitas por Período

Comportamento de visitas por dia da semana e mês

1/2



Visitas por Categoria e Período (semanal e mensal)

Categoria

All


Ano

All

Mês

All

Distribuição de visitas por dia da semana



> Visualização referente à quantidade de visitas por categoria e dias da semana.

Dashboard · Visitas por Período

Comportamento de visitas por dia da semana e mês

2/2

Distribuição de visitas por mês



> Visualização referente à quantidade de visitas por categoria e meses do ano (de acordo com os filtros aplicados).

Dashboard · Usuários da Plataforma

Influência dos usuários

1/3



Estado

All

Total Usuários

1,33 mi

Top Usuários de Estabelecimentos de Alimentação

Top 10 Usuários da plataforma

Nome	Score	Reviews	Fãs	Data de cadastro	Elite
GERALD	318	1131	703	12/2012	2013,2014,2015,2016,2017,2018,2019,2020,2021
KAREN	313	1299	558	05/2008	2008,2009,2010,2011,2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
MICHELLE	311	863	1353	03/2008	2008,2009,2010,2011,2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
BOON	304	952	387	05/2014	2014,2015,2016,2017,2018,2019,2020,2021
MICHAEL	302	647	1251	10/2010	2013,2014,2015,2016,2017,2018,2019,2020,2021
BRETT	302	763	914	01/2012	2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
MARIELLE	299	892	379	12/2010	2011,2012,2013,2014,2015,2016
STEVEN	298	849	401	08/2010	2010,2011,2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
CHRISTINA	293	649	669	10/2012	2013,2014,2015,2016,2017,2018,2019,2020,2021


> Painel para elencar os top usuários da plataforma, de acordo com o score calculado.

Dashboard · Usuários da Plataforma

Influência dos usuários

2/3

Distribuição de status Elite



Status: ■ Non-Elite ■ Elite

Distribuição de usuários por estado



> Visualização agrupada de acordo com os status dos usuários e valores totais por região.

Dashboard · Usuários da Plataforma

Influência dos usuários

3/3

Top Usuários por Estado

Nome	Estado	Score no estado	Reviews	Fãs	Data de cadastro	Elite
KAREN	PA	310	1189	558	05/2008	2008,2009,2010,2011,2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
GERALD	PA	308	836	703	12/2012	2013,2014,2015,2016,2017,2018,2019,2020,2021
MICHELLE	PA	304	694	1353	03/2008	2008,2009,2010,2011,2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
BOON	FL	304	938	387	05/2014	2014,2015,2016,2017,2018,2019,2020,2021
MICHAEL	NV	302	645	1251	10/2010	2013,2014,2015,2016,2017,2018,2019,2020,2021
BRETT	FL	301	731	914	01/2012	2012,2013,2014,2015,2016,2017,2018,2019,2020,2021
MARIELLE	LA	299	892	379	12/2010	2011,2012,2013,2014,2015,2016

< 1 2 3 4 5 ... 10000 >

Truncated data ✕

> Identificação de top usuários detalhada por região.

Dashboard · Detecção de Inconsistências

Suspeita de avaliações inconsistentes ou com suspeita de fraude

1/4



Detecção de avaliações inconsistentes - Visão consolidada

Total de Reviews

4,09 mi

Reviews Inconsistentes

280,46 mil


Reviews Válidas

3,81 mi

% Inconsistências

6,74%

Distribuição Temporal - Inconsistentes vs Válidas



> Identificação de reviews inconsistentes ou com suspeita de fraude, destacando em quais períodos do dia elas costumam ocorrer.

Dashboard · Detecção de Inconsistências

Suspeita de avaliações inconsistentes ou com suspeita de fraude

2/4

Top 20 Estabelecimentos com Reviews Inconsistentes



Última Review	ID Estabelecimento	Nome do Estabelecimento	Categoria	Total de Reviews	Reviews Inconsistentes	% Inconsistências
2022-01-08	PP3BBaVxZLcJU54uP_wL6Q	PAT S KING OF STEAKS	RESTAURANTE	4293	4293	100,00
2022-01-16	IkY2ticzHEn4QFn8hQLSWg	GENO S STEAKS	RESTAURANTE	3428	3428	100,00
2022-01-19	ORL4JE6tz3rJxVqkdKfegA	GAYLORD OPRYLAND RESORT & CONVENTION CENTER	RESTAURANTE	1670	1670	100,00
2022-01-19	ve_rPLEGPClytyJtY55Vw	NUGGET CASINO RESORT	RESTAURANTE	1653	1653	100,00
2022-01-15	Id_H5-FpZOWm_tkzmkPYQQ	SILVER LEGACY RESORT CASINO	RESTAURANTE	1620	1620	100,00
2022-01-18	8A5LSwsKK5vXDH1M3_Tf1w	THE RITZ CARLTON BACARA	RESTAURANTE	1449	1449	100,00
2022-01-16	FaY_9x8ZtsuHe5wS2iJM1Q	VERTI MARTE	RESTAURANTE	1354	1354	100,00
2022-01-18	rSYyGcZZziJLsqKl5hMcDw	CIRCUS CIRCUS RENO	RESTAURANTE	1292	1292	100,00
2022-01-13	J6ZSgoKCLBDMzuhlM-aYGg	ELDORADO RESORT CASINO	RESTAURANTE	998	998	100,00
2022-01-17	SwBhaxfQPbyhsi0QHJUANOA	SEMINOLE HARD ROCK HOTEL & CASINO TAMPA	RESTAURANTE	821	821	100,00
2022-01-10	jXrhlVKcJ-upvgUmfC1pA	CLOVER GRILL	RESTAURANTE	777	777	100,00
2022-01-13	WNhcS2zi4zAqA2TbduVINQ	CLEO S	RESTAURANTE	775	775	100,00
2022-01-12	nB7LcJlvZr-EbJj4oFZf-A	DAISY DUKES EXPRESS	RESTAURANTE	718	718	100,00
2022-01-16	zJjfjg_zTL3ceGi_Vr4OFw	SHERATON NEW ORLEANS HOTEL	RESTAURANTE	688	688	100,00
2022-01-07	7_kXuKFruGrrRauN9rLJ1g	LUCKY BEAVER BAR & BURGER	RESTAURANTE	613	613	100,00
2022-01-16	IZX5_8qspEXtMJGFQ0-Mow	PHILADELPHIA MARRIOTT DOWNTOWN	RESTAURANTE	609	609	100,00

> Top 20 Estabelecimentos com Reviews Inconsistentes, para possível necessidade de auditoria interna dentro da plataforma.

Dashboard · Detecção de Inconsistências

Suspeita de avaliações inconsistentes ou com suspeita de fraude

3/4

Mensagens de Alerta de Inconsistências

Detalhamento de todos os alertas de inconsistências por usuário e estabelecimento




Última Review	ID Estabelecimento	Estabelecimento	Categoria	Tipo de Alerta	Total Inconsistências	% Inconsistências	Mensagem de Alerta
2022-01-08	PP3BBaVxZLcJU54uP_wL6Q	PAT S KING OF STEAKS	RESTAURANTE	ESTABELECIMENTO	4293	100,00	Estabelecimento PAT S KING OF STEAKS
2022-01-16	IkY2ticzHEN4QFn8hQLSWg	GENO S STEAKS	RESTAURANTE	ESTABELECIMENTO	3428	100,00	Estabelecimento GENO S STEAKS
2022-01-19	ORL4JE6tz3rJxVqkdKfegA	GAYLORD OPRYLAND RESORT & CONVENTION CENTER	RESTAURANTE	ESTABELECIMENTO	1670	100,00	Estabelecimento GAYLORD OPRYLAND RESORT & CONVENTION CENTER
2022-01-19	ve_rPLEGPClytyJtY55Vw	NUGGET CASINO RESORT	RESTAURANTE	ESTABELECIMENTO	1653	100,00	Estabelecimento NUGGET CASINO RESORT
2022-01-15	ld_H5-FpZOWm_tkzwwPYQQ	SILVER LEGACY RESORT CASINO	RESTAURANTE	ESTABELECIMENTO	1620	100,00	Estabelecimento SILVER LEGACY RESORT CASINO
2022-01-18	8A5LSwsKK5vXDH1M3_Tf1w	THE RITZ CARLTON BACARA	RESTAURANTE	ESTABELECIMENTO	1449	100,00	Estabelecimento THE RITZ CARLTON BACARA
2022-01-16	FaY_9x8ZtsuHe5wS2IJM1Q	VERTI MARTE	RESTAURANTE	ESTABELECIMENTO	1354	100,00	Estabelecimento VERTI MARTE
2022-01-18	rSYyGcZZziJLsqKl5hMcDw	CIRCUS CIRCUS RENO	RESTAURANTE	ESTABELECIMENTO	1292	100,00	Estabelecimento CIRCUS CIRCUS RENO
2022-01-13	J6ZSgoKCLBDMmZuhM_aYGg	ELDORADO RESORT CASINO	RESTAURANTE	ESTABELECIMENTO	998	100,00	Estabelecimento ELDORADO RESORT CASINO
2022-01-17	SwBhaxfQPbyhsi0QHJUAN0A	SEMINOLE HARD ROCK HOTEL & CASINO TAMPA	RESTAURANTE	ESTABELECIMENTO	821	100,00	Estabelecimento SEMINOLE HARD ROCK HOTEL & CASINO TAMPA
2022-01-10	jXrhlVKcJ-upvglUmfc1pA	CLOVER GRILL	RESTAURANTE	ESTABELECIMENTO	777	100,00	Estabelecimento CLOVER GRILL
2022-01-13	WNhcS2zi4zAqA2TbduVINQ	CLEO S	RESTAURANTE	ESTABELECIMENTO	775	100,00	Estabelecimento CLEO S (ID: WNhcS2zi4zAqA2TbduVINQ)
2022-01-12	nB7LcJlvZr-EbjJ4oFZf-A	DAISY DUKES EXPRESS	RESTAURANTE	ESTABELECIMENTO	718	100,00	Estabelecimento DAISY DUKES EXPRESS

> Geração de mensagens de alertas relacionados aos estabelecimentos e usuários com reviews inconsistentes.

Dashboard · Detecção de Inconsistências

Suspeita de avaliações inconsistentes ou com suspeita de fraude

4/4



> Por exemplo:

Muitas avaliações realizadas em dias em que um estabelecimento está fechado pode indicar que há uma **necessidade de atualização cadastral** ou que os usuários em questão estão com um comportamento que pode indicar uma **suspeita de fraude**, no caso, com o objetivo de melhorar a nota do estabelecimento dentro da plataforma.

Desafios e Lições Aprendidas

O que enfrentamos e o que levamos



Desafios Enfrentados

- **Limitações do Ambiente Free:** A versão gratuita restringiu o desenvolvimento a um único usuário e impôs limites de processamento e consumo de memória.

Além disso, apenas um Workspace foi disponibilizado, o que dificultou a criação de múltiplos ambientes como os de Desenvolvimento, Homologação e Produção (simulando uma implantação corporativa).

- **Manipulação de JSONs:** O tratamento de campos em formato json exigiu lógicas complexas para obter as informações de maneira que facilitasse os agrupamentos e joins entre as tabelas.



Lições Aprendidas

- **Data Quality:** Funções padronizadas de controle na Silver economizaram horas de depuração na camada Gold.
- **Boas práticas de processamento:** Uso de *overwrite* e *overwriteSchema* evitou duplicação e quebras no pipeline.
- **Padronização de dados:** Padronização de prefixos e caracteres foi essencial para a integridade dos dados (principalmente, para os KPIs por localidades).
- **Afunilamento de escopo:** Refinar perguntas de negócio (ex: focar em alimentação) garantiu entregas de valor real.

Próximos Passos e Conclusão

Para onde o projeto pode evoluir

01

Melhoria e Automação da Ingestão

Implementar ferramentas de automação para realizar atualizações incrementais, aliadas a um monitoramento contínuo de falhas e regras automáticas de qualidade de dados.

02

Detecção Avançada de Fraudes (NLP)

Melhorar a detecção de inconsistências aplicando NLP para identificar avaliações genéricas e criar métricas de velocidade de postagem e localização de usuários suspeitos.

03

Otimização de Desempenho Visual

Reorganizar o armazenamento na camada Gold, particionando por dia e agrupando por assuntos, acelerando o carregamento e filtragem nos dashboards.

04

Enriquecimento do Escopo Analítico

Expandir o escopo das análises aproveitando a totalidade das categorias originais e a vasta gama de atributos técnicos disponíveis na API do Yelp.



Obrigado!



Dúvidas?



Disciplina: eEDB-015/2026-1 - Projeto Integrador

Grupo B:

Ana Carolina Kubo

Danilo de Souza Silva

Jefferson da Silva Almeida

Willian Camargo Aires Maranhão

Dashboard · Visão Geral de Estabelecimentos de Alimentação

Explicação rating yelp

$$\text{rating_yelp} = (m \times C + S) / (m + n)$$

m = mediana de reviews da plataforma;

C = média global de estrelas;

S = soma total de estrelas do restaurante;

n = número de reviews do restaurante;

m = mediana de reviews da plataforma;

C = média global de estrelas;

S = soma total de estrelas do restaurante;

n = número de reviews do restaurante;

Exemplo:

100 reviews

Soma de estrelas = 450 (média de 4.5)

$$\text{rating_yelp} = (35 \times 3.8441 + 450) / (35 + 100)$$

$$\text{rating_yelp} = (134.54 + 450) / 135$$

$$\text{rating_yelp} = 4.33$$

Objetivos do Projeto

O que nos propusemos a construir

Objetivos de Negócio

Mapeamento de Excelência: Descobrir os melhores restaurantes por categoria e localidade para guiar oportunidades de expansão.

Análise de Sazonalidade: Identificar os dias e meses com menos visitas para impulsionar campanhas de vendas e cupons promocionais.

Auditoria e Fraude: Identificar estabelecimentos com avaliações inconsistentes para auditoria da plataforma.

Identificação de Influência: Mapear os Top 10 usuários para fomento de contratos de criação de conteúdo.

sett

ing

Objetivos Técnicos

np

ut

co

mp

one

lay

ers

Pipeline End-to-End

Construir a ingestão automatizada no Databricks, conectando o Yelp Open Dataset até a camada visual.

Arquitetura Medalhão

Implementar as camadas Bronze, Silver e Gold para garantir governança, rastreabilidade e qualidade.

Plataforma Databricks

Ambiente unificado de dados e IA

Pessoa 2



Lakehouse Architecture

Combina a flexibilidade de data lakes com a confiabilidade de data warehouses, centralizando armazenamento e processamento em uma única plataforma.



Apache Spark Nativo

Processamento distribuído de grande volume com suporte a batch e stream usando Python (PySpark) e SQL com clusters gerenciados.




Delta Lake + Notebooks



Databricks Workflows
(Módulo Orquestrador)

Databricks UnityCatalog



Apache Spark
(Motor de Processamento)

Workspace colaborativo com clusters configurados para processamento

Dashboard · Usuários da Plataforma

Influência dos usuários

Score com escala logarítmica:

- Evitar distorções
- Equilibrar usuários pequenos e grandes
- Ranking mais saudável
- Excelente para rankings
- Evita explosões absurdas no ranking
- Reviews são o fator principal
- Fãs ajudam
- Qualidade das reviews importa (reações)

$$\begin{aligned}\text{Score} = & (\log_{10}(\text{reviews} + 1) * 70) \\ & + (\log_{10}(\text{fans} + 1) * 20) \\ & + (\log_{10}(\text{total_reactions} + 1) * 10)\end{aligned}$$

